AI 的進化：
從 RAG 到自主 Agent

從「隨身助理」到「自主執行者」的技術躍遷

報告人: 方欽賢 | 2025 年

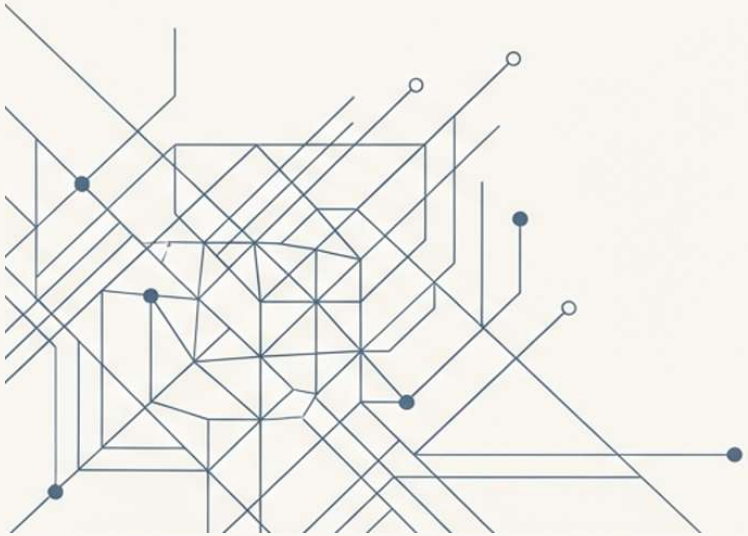

報告大綱

1. 大腦與侷限

AI 的基礎能力與其根本缺陷。

2. 開卷考試

賦予 AI 外部記憶，解決知識侷限。

3. 精準查資料

優化 AI 的記憶檢索能力，確保準確性。

4. 手與腳

讓 AI 超越問答，具備執行任務的能力。

5. 實踐與未來

整合所有能力，展望 AI 的下一戰場。

LLM：強大但健忘的大腦

LLM 是 AI 的核心，擁有強大的語言理解與生成能力，
但基礎存在兩個致命缺陷，使其無法單獨應對真實世界的任務。

⚠ 兩大缺陷

知識停滯 (Static Knowledge)

模型訓練完成後，其知識庫便不再更新。

幻覺 (Hallucination)

當模型不知道答案時，傾向於捏造看似真實的資訊，也就是「一本正經說瞎話」。

解決方案：給 AI 開卷考試

RAG (檢索增強生成)讓LLM 在回答前先「查資料」,從根本上解決知識停滯與幻覺問題。

關鍵機制　**知識透過 Embedding 技術被翻譯成「數學座標」,**
存儲在向量資料庫中,實現基於「意義」的快速查找。

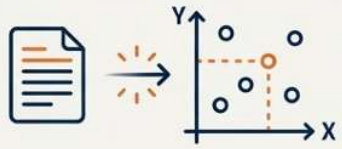

Embedding：將「知識」翻譯成「座標

- **1. 切塊 (Chunking)**
  將長文件切分成小段落。
- **2. 向量化 (Embedding)**
  將文字轉化為多維數學座標。
- **3. 儲存 (Storage)**
  存入向量資料庫 (Vector DB)。
- **4. 搜尋 (Search)**
  計算座標距離 (Cosine Similarity) 尋找近鄰。

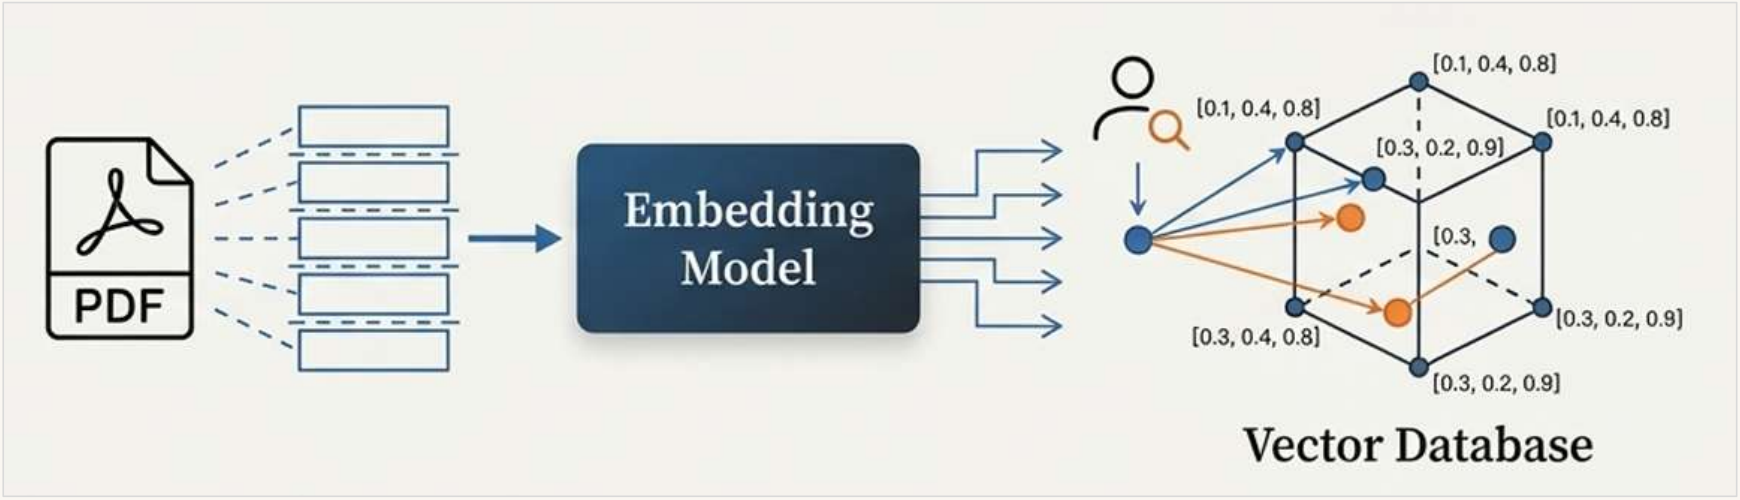

傳統 RAG 的痛點：上下文失憶

傳統 RAG 在處理文件時,會將其「粗暴地切塊」(Chunking),導致每個區塊內的資訊與其原始上下文脫鉤。

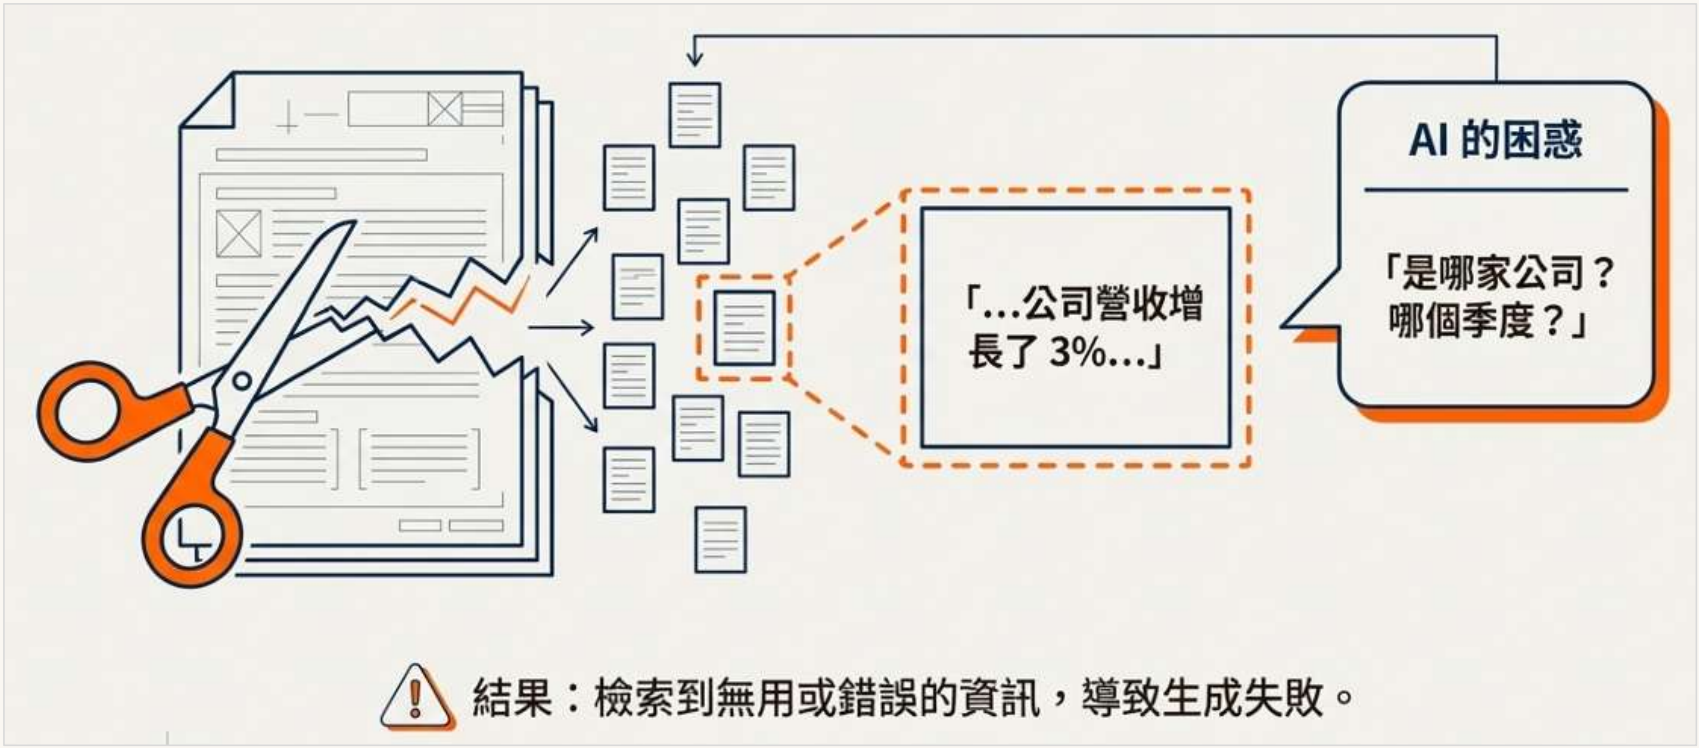

各種RAG方案：精準度 VS 實現成本

架構類型	實現複雜度	索引成本 (CapEx)	查詢成本/延遲 (OpEx)	維護難度
Naive RAG	低	低	低	低
Hybrid + Rerank	中 (需維護雙索引)	中	中 (重排序計算)	中
Agentic RAG	極高 (開場辨與 Prompt工程)	低	極高 (多輪調用)	高 (Prompt 漂移)
GraphRAG	高 (圖譜工程)	極高 (LLM 提取)	中	高 (重索引困難)
LazyGraphRAG	高	極低 (延遲計算)	中/高 (取決於深度)	中
LightRAG	中/高	低	低	低 (增量更新)

零程式碼 RAG 工具：Google NotebookLM

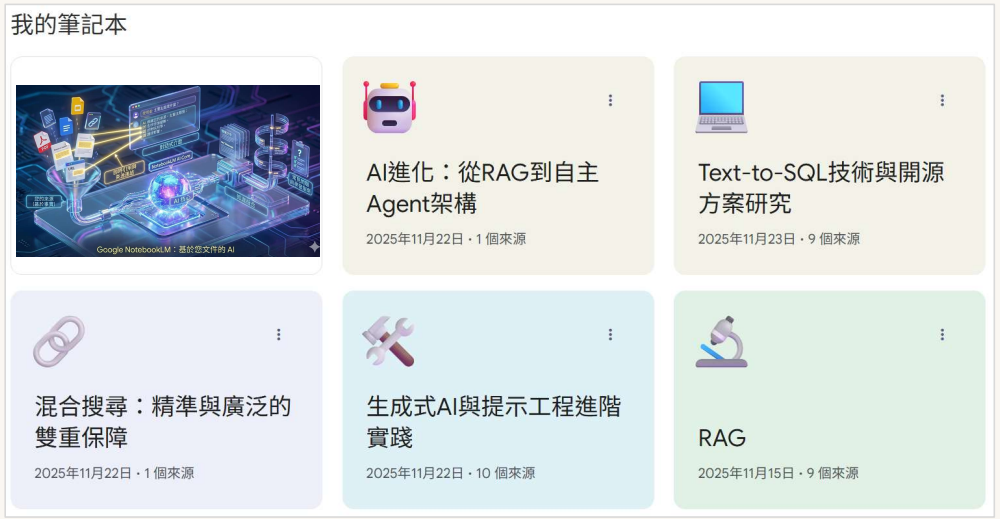

支援的檔案類型：
PDF，.txt，Markdown，音訊（例如 MP3），.avif，.bmp，.gif，.ico，.jp2，.png，.webp，.tif，.tiff，.heic，.heif，jpeg，.jpg，jpe

功能項目	免費版	Pro 版
可建立筆記本數量	最多 **100** 個	最多 **500** 個
每個筆記本的來源上限	**50** 個來源	**300** 個來源
每個來源字數上限	**50** 萬字	**50** 萬字（相同）
每日對話查詢次數	**50** 次	**500** 次
每日語音生成次數	**3** 次	**20** 次
每日影片生成次數	**3** 次	**20** 次

原文連結: [Contextual Retrieval in AI Systems \ Anthropic]

手刻 RAG 改善方案一：Contextual Retrieval

方法原理: 從「上下文失憶」到「情境檢索」

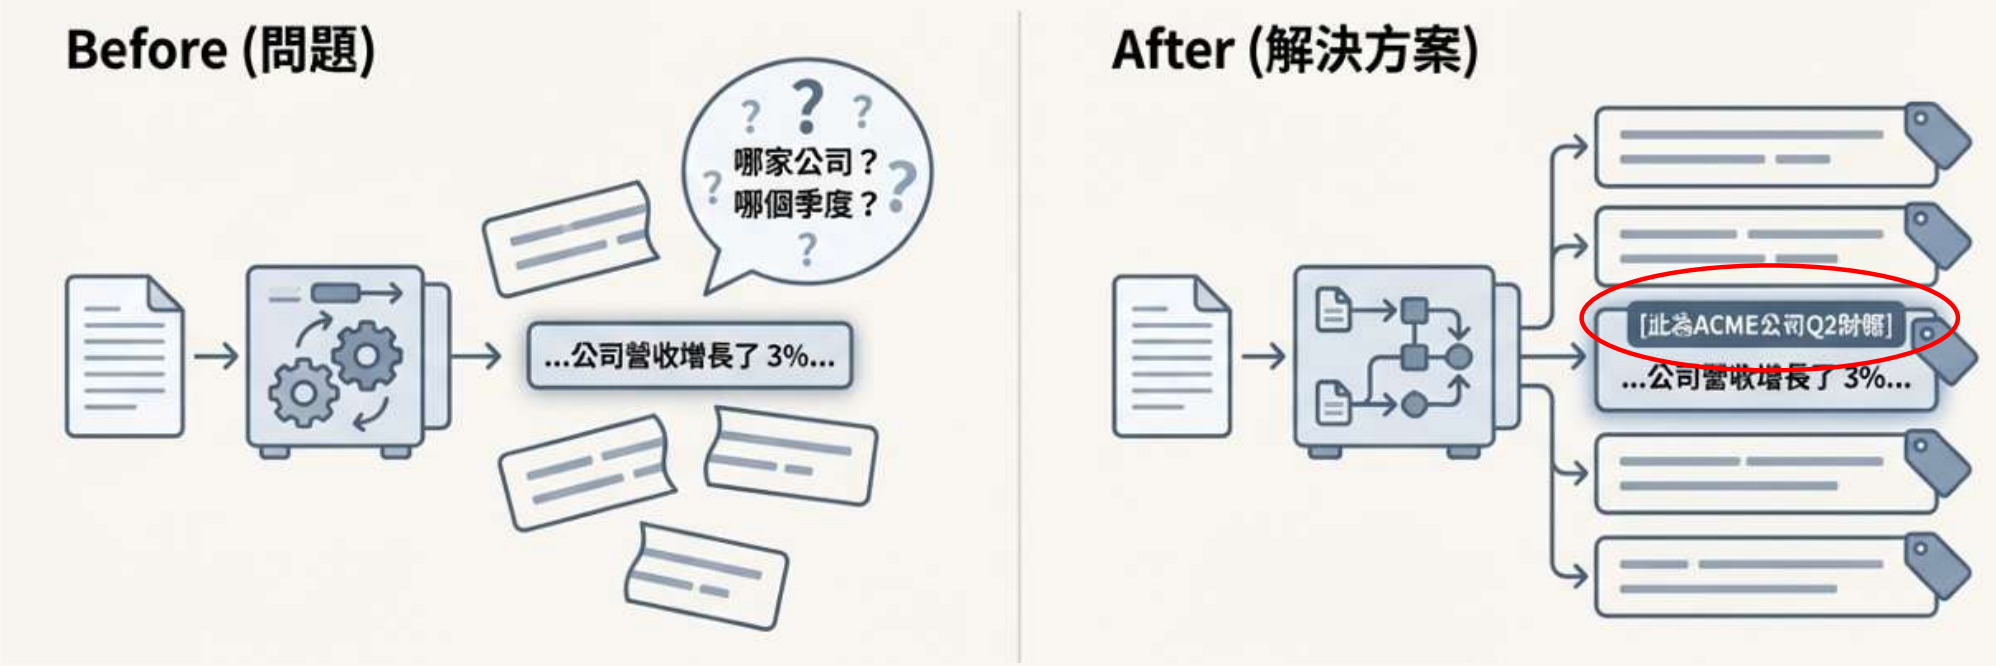

傳統的「粗暴切塊」會導致關鍵資訊遺失,造成「上下文失憶」。

為每個區塊「注入上下文」,讓其自帶說明書。根據Anthropic 的研究,此方法可使檢索失敗率降低49%。

手刻 RAG 改善方案一：Contextual Retrieval

實現工具包: LLM + N8N + Supabase

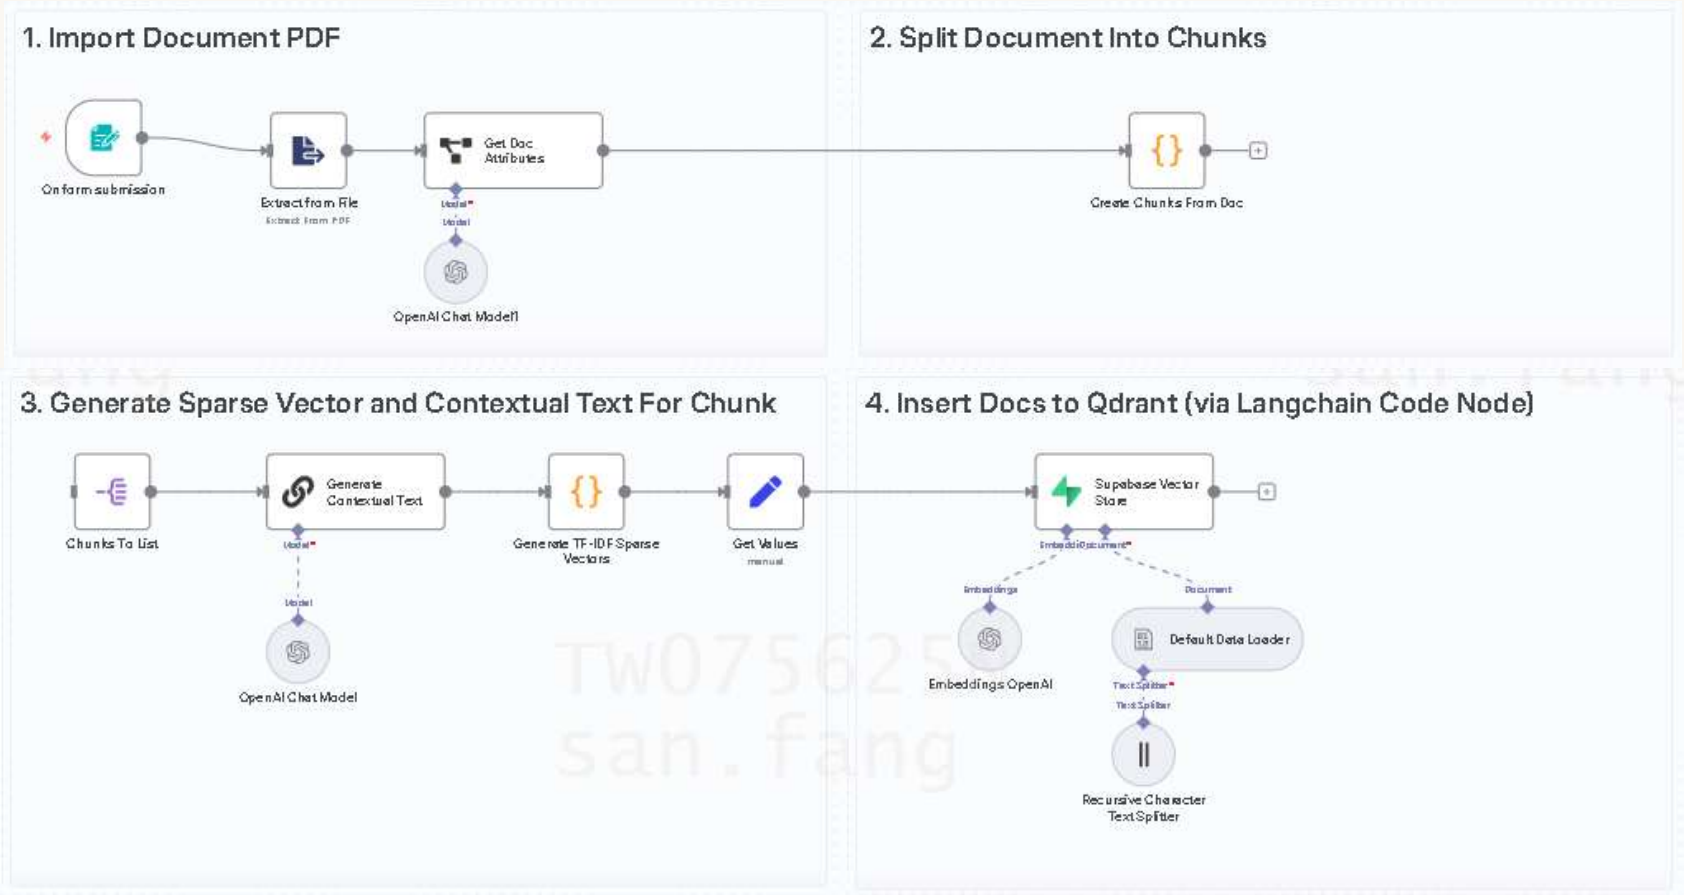

原文連結: [Hybrid search | Supabase Docs]

手刻 RAG 改善方案二： 混合搜尋 (Hybrid Search)

方法原理: 關鍵字 vs 語意？ 能不能兩者都要

僅依賴語意搜尋(Semantic Search)是不夠的。 某些查詢需要絕對的精確度。

原文連結: [Hybrid search | Supabase Docs]

手刻 RAG 改善方案二：混合搜尋 (Hybrid Search)

實現工具包: LLM + N8N + Supabase

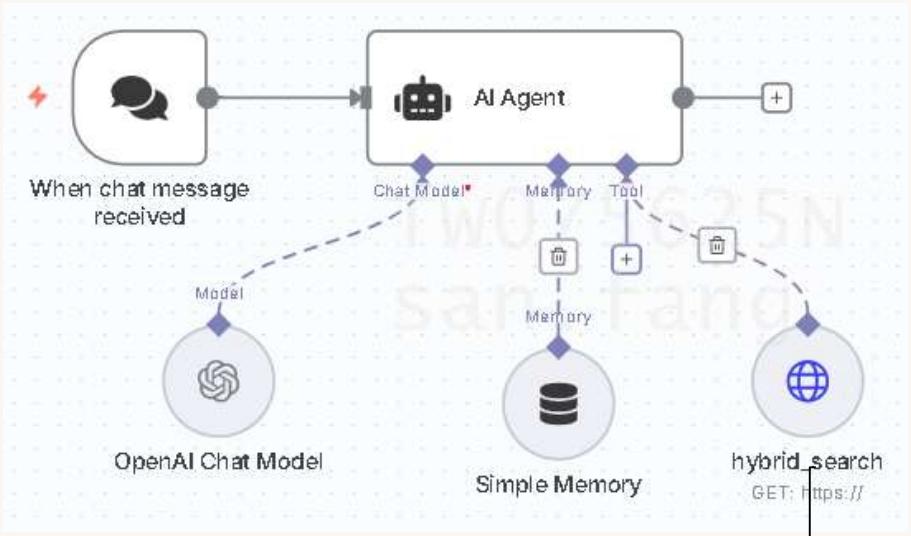

Definition

The language below should be written in sql.

```sql
with full_text as (
  select
    id,
    -- Note: ts_rank_cd is not indexable but will only rank matches of
    the where clause
    -- which shouldn't be too big
    row_number() over(order by ts_rank_cd(fts, websearch_to_tsquery
    (query_text)) desc) as rank_ix
  from
    documents
  where
    fts @@ websearch_t
    and metadata @> fi
  order by rank_ix
```

建立 Hybrid Search
自動產生 API

INVOKE FUNCTION

```sql
let { data, error } = await supabase
  .rpc('my_hybrid_search', {
    filter,
    full_text_weight,
    match_count,
    query_embedding,
    query_text,
    rrf_k,
    semantic_weight
  })
if (error) console.error(error)
else console.log(data)
```

混合搜尋 (Hybrid Search)：應用場景

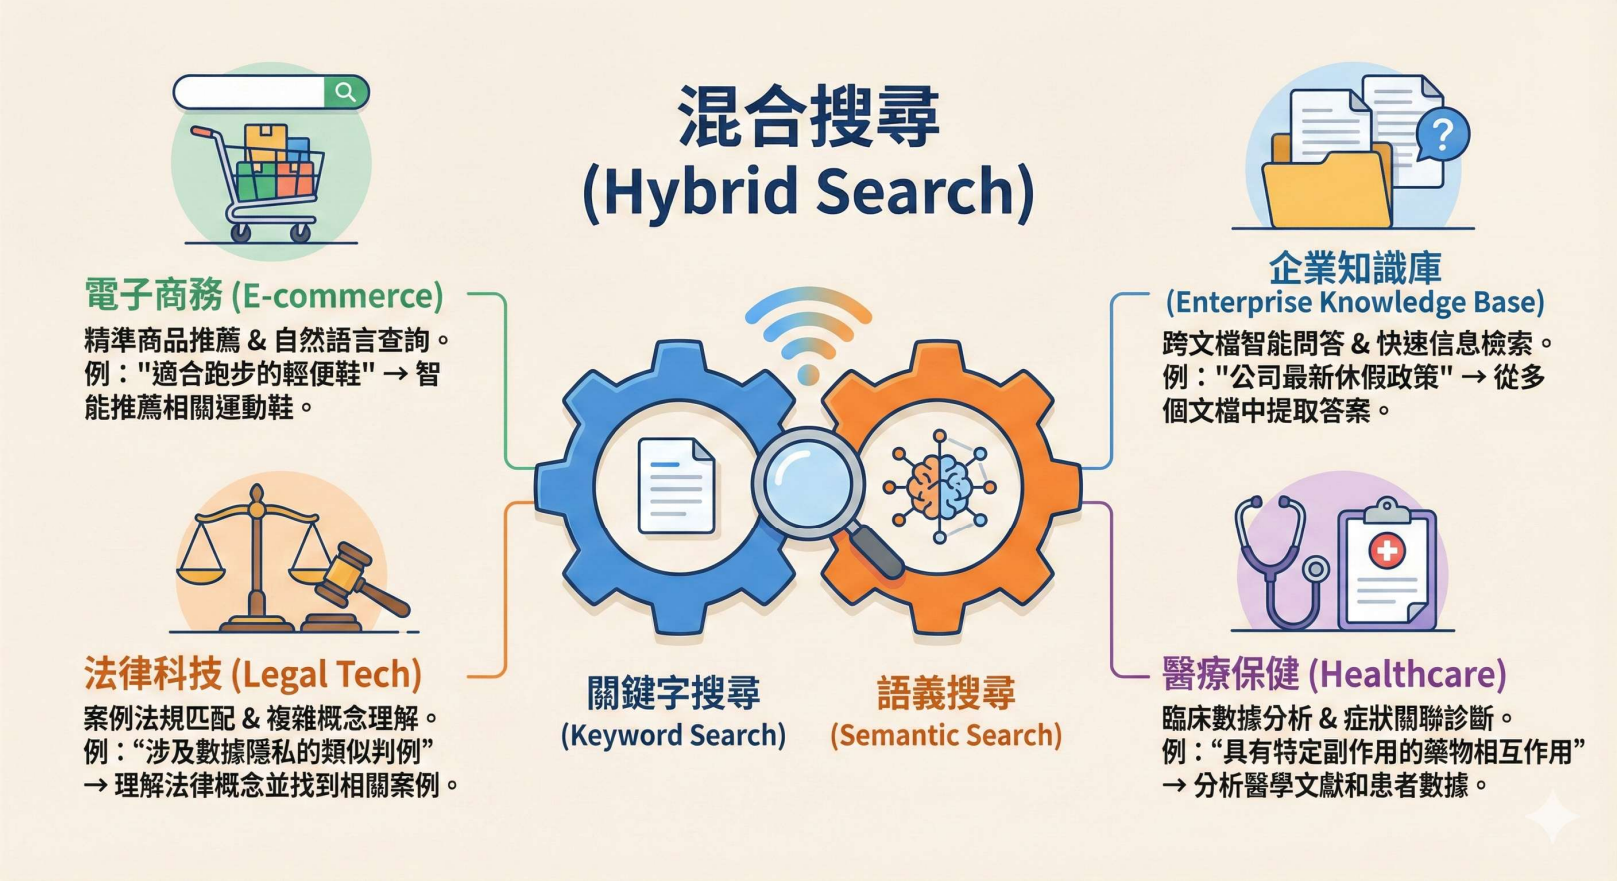

精準檢索: AI 的雙重搜尋策略

為了應對不同類型的資料, AI需要結合多種檢索工具。

針對非結構化文本(如 PDF, TXT)

策略：混合搜尋（Hybrid Search）

結合關鍵字搜尋(Keyword)的「精」與語意搜尋(Semantic)的「廣」,實現「精確匹配」與「相關推薦」的雙重保障。

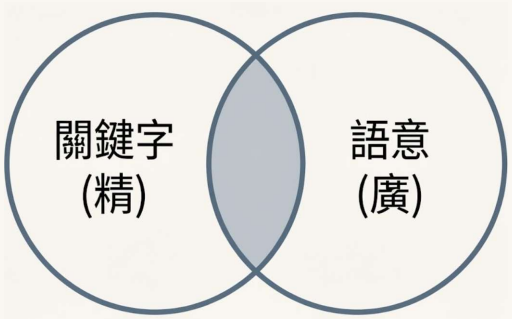

針對結構化數據(如資料庫)

策略：Text-to-SQL

將「人話」的自然語言查詢,直接翻譯成「SQL程式碼」,讓AI 能夠讀懂並分析資料庫中的表格
數據。

結構化資料庫:Text-to-SQL 讓AI 讀懂資料庫

AI 的能力不應侷限於讀懂 PDF或網頁。 Text-to-SQL技術讓AI 能夠直接查詢結構化資料庫,
徹底解鎖其數據分析潛力。

從數日到數秒:數據查詢的進化

過去的低效循環

「過去，領導、決策者或業務人員想要統計個數據、做個報告，總是繞不開技術人員的支持……整個過程非常低效！」

未來的即時對話

數據民主化：賦能非技術人員

Text-to-SQL : 正在賦能千行百業

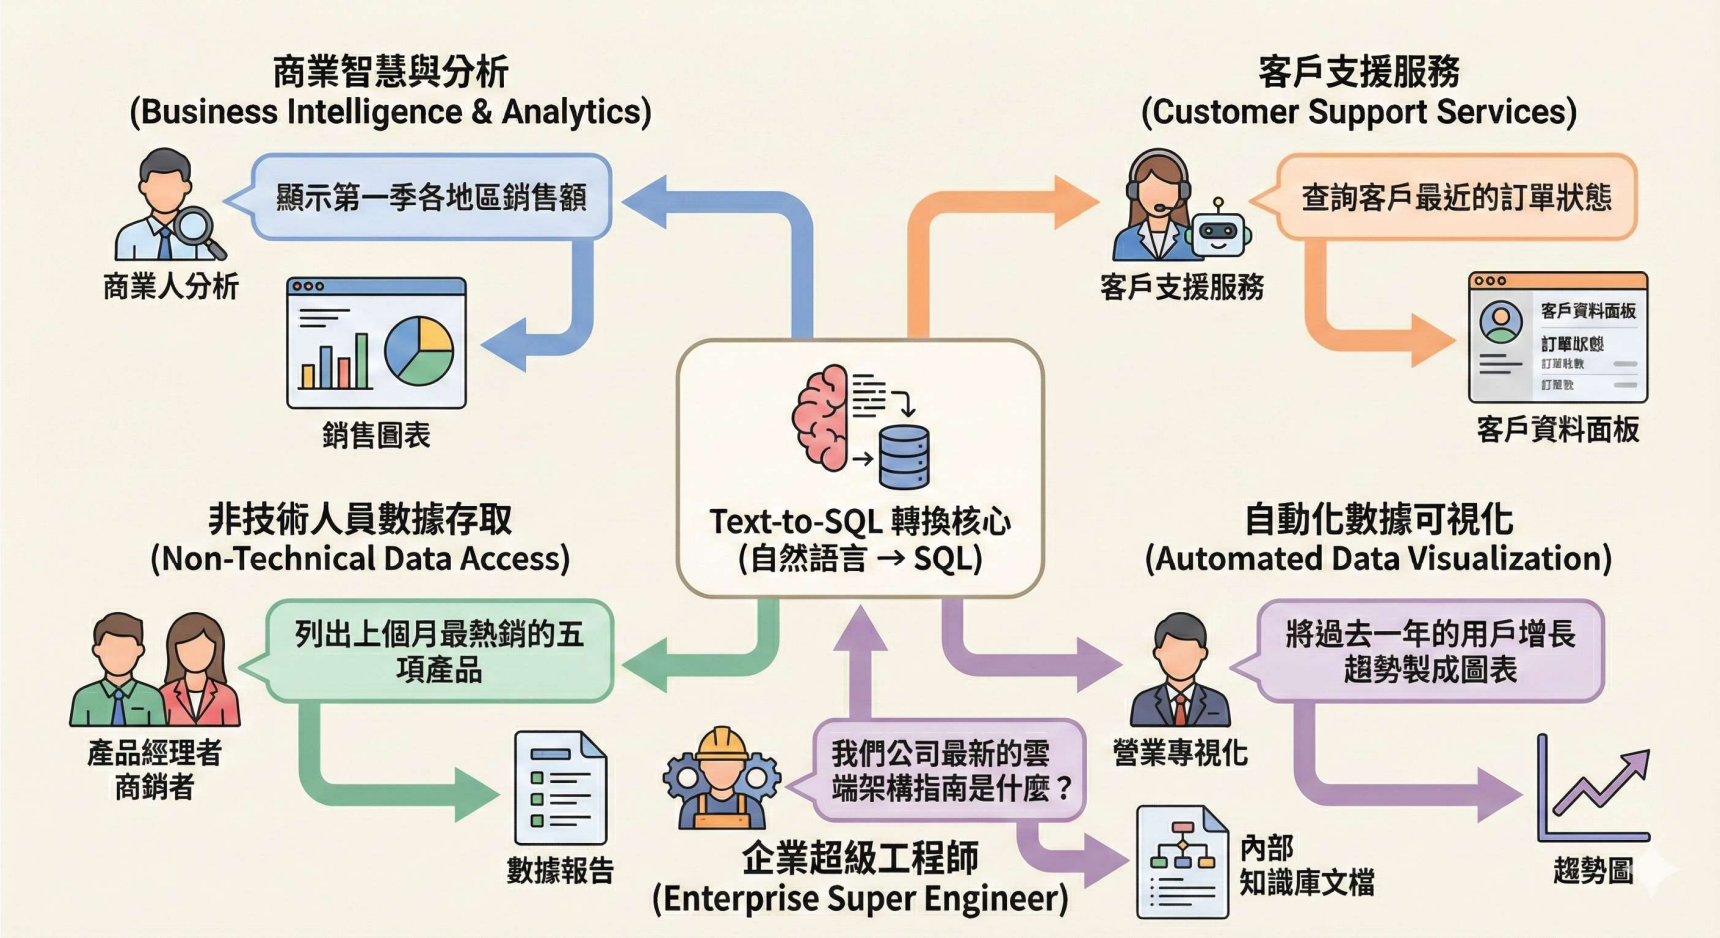

Text-to-SQL ： 超級工程師

實現工具包: LLM + Python+ Nodejs + 結構化資料庫

AI 的下個進化:從「聊天」的AI到「做事」的Agent

Agent = LLM（大腦）+ Tools（手與腳）

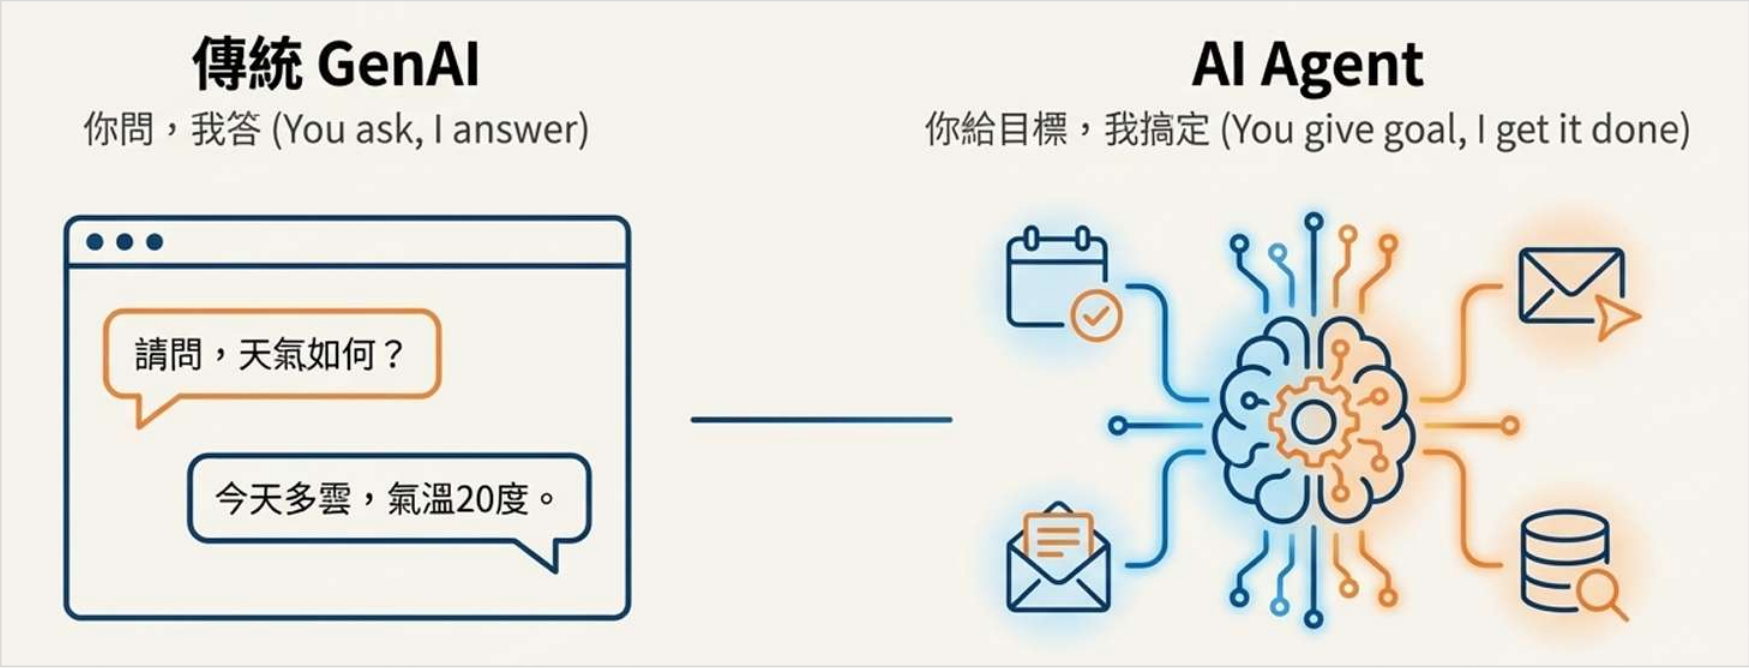

Agent 如何使用「工具」？ 語言與協定

指令語言- 函數呼叫（Function Calling）

Agent 使用工具的技術基礎,是一種比提示詞(Prompt)更穩定、更結構化的 API 請求。

通用協定-模型上下文協定（Model Context Protocol）

MCP 是「AI的USB」

解決的痛點:「每家公司的工具/API 格式都不同,整合困難。」

MCP 的作用：「建立 Agent 和 Tool 之間的「通用語言」,讓任何 Agent 都能「隨插即用」任何工具,實現跨平台的工具生態系。」

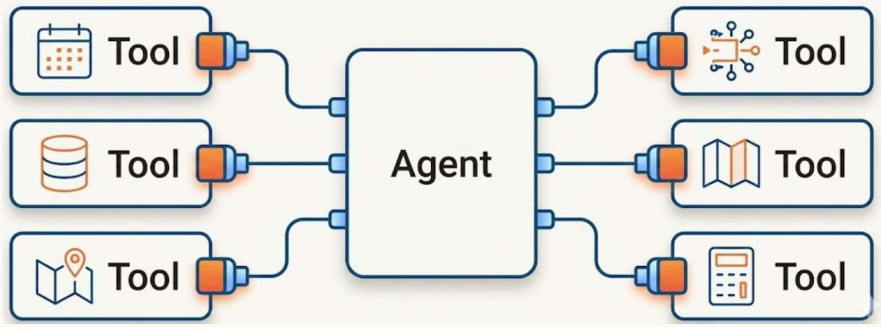

MCP 範例一：圖表生成工具 ECharts

gpt-4.1 今天 09:47

這是你所需要的半年財報曲線圖連結：

👉 點我看半年財報據曲線圖 📈

圖表中，你可以清楚看到未來新股份有限公司在2024年上半年，各項財務指標如營收、毛利、淨利等的走勢。從Q1到Q2的明顯成長，證明公司策略奏效！

如果你需要不同項目分開呈現，或是想要更多細項數據，也可以再告訴我喔！🤗

1 個來源

工具 3

PPC_達產

圖表工具

Chrome DEV TOOLS

1

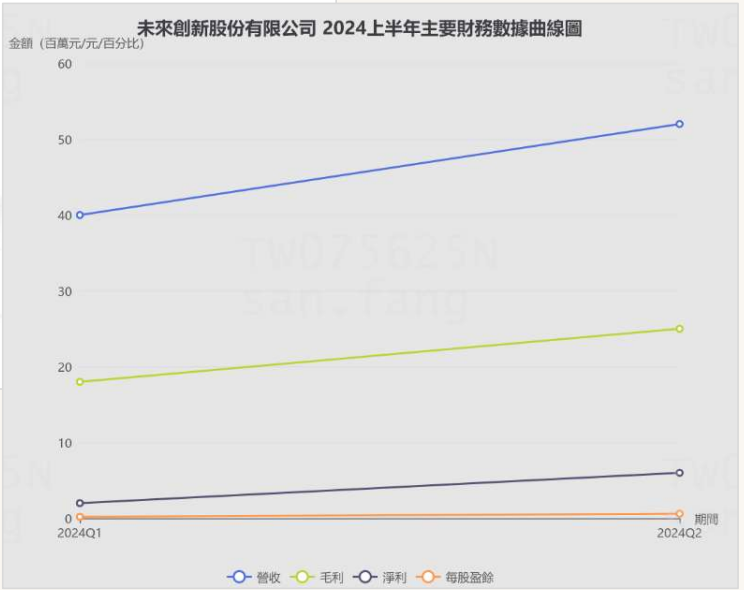

MCP 範例二：待補

AI Agent：從「知識庫」到「行動者」的進化路徑

AI Agent 工具：N8N 作業流程自動化工具特點

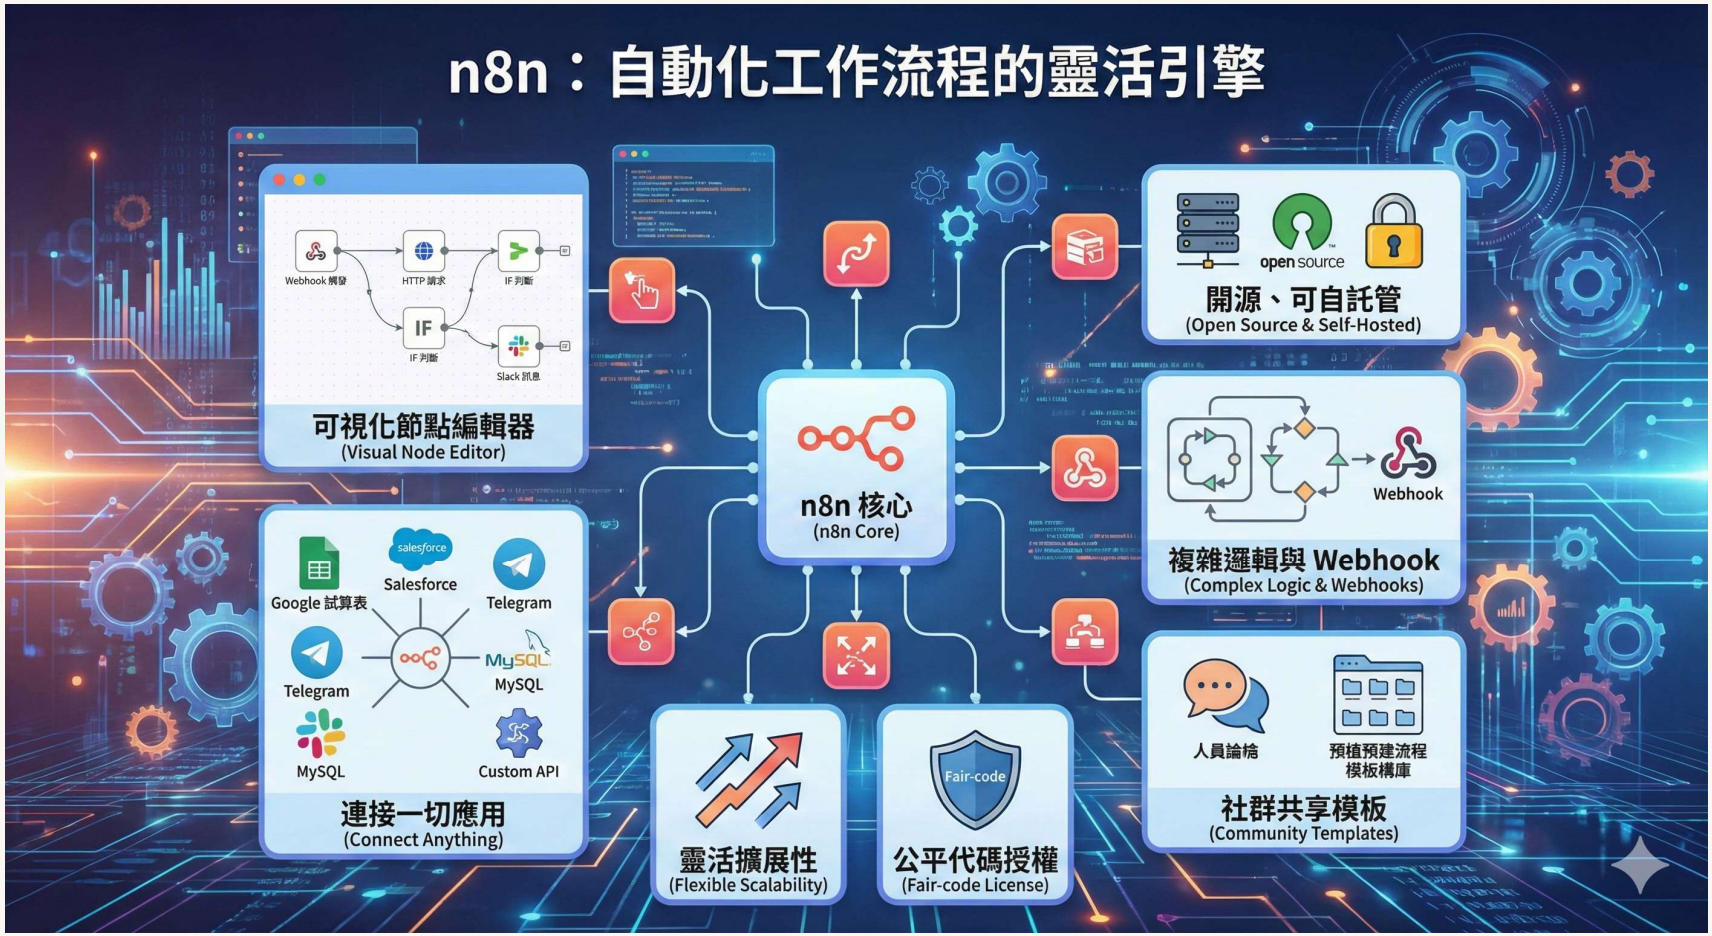

實作落地一：用 N8N 組裝自己的知識小助手

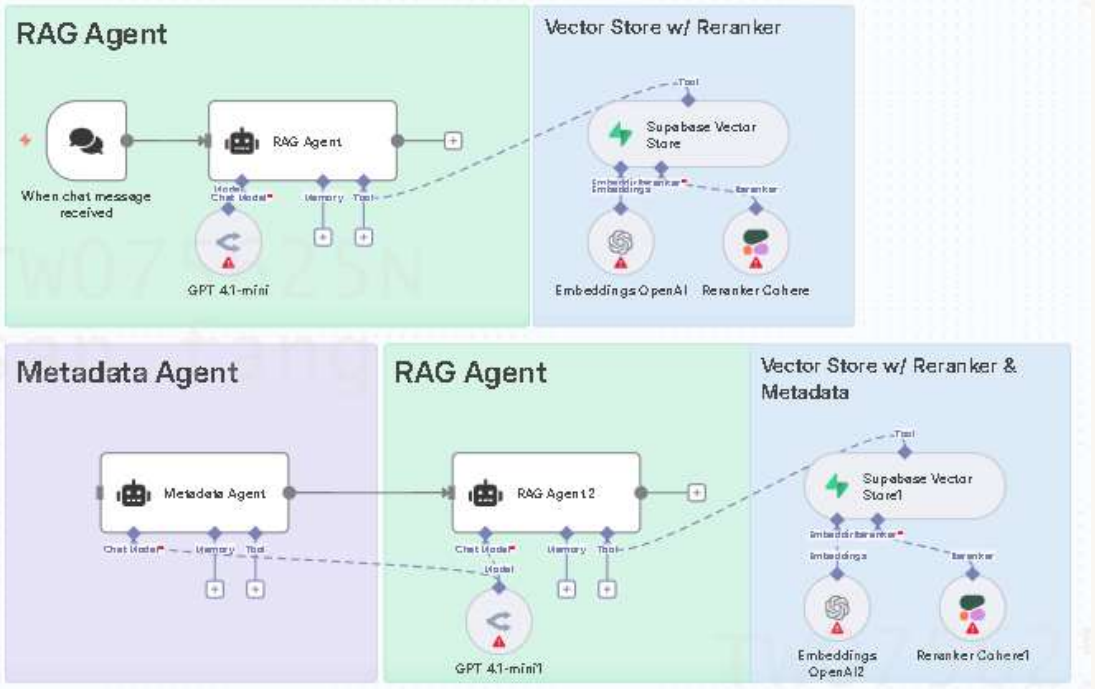

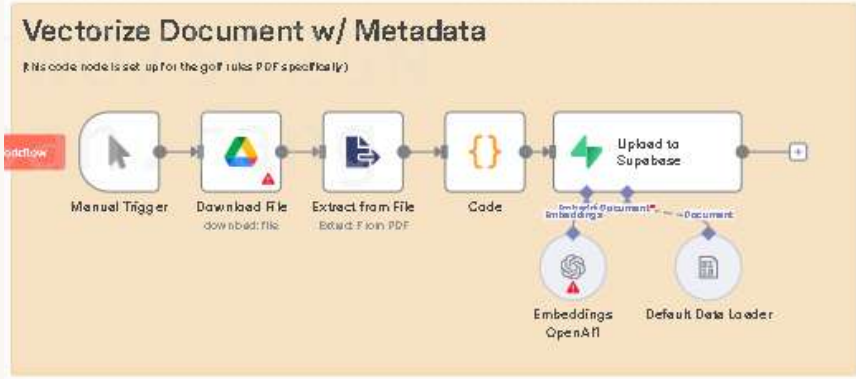

實作落地二：待補

未來展望：自主生產力時代

RAG

將成為標配

Agent

將無所不在

MCP

生態系護城河

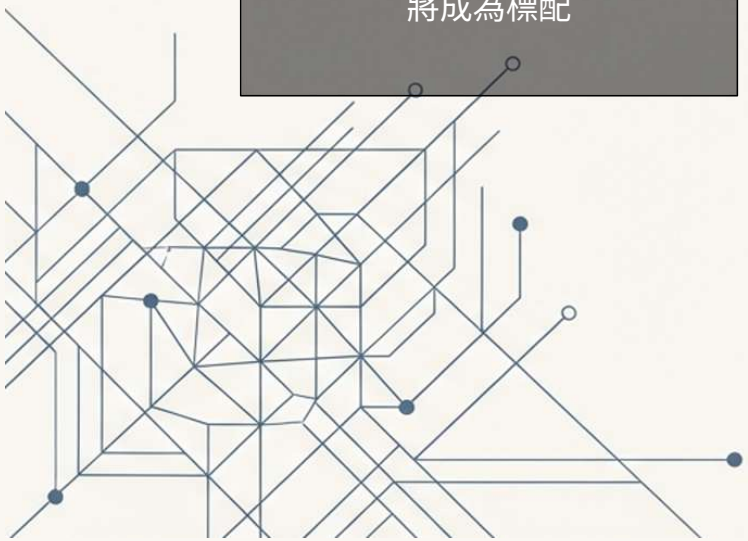

Q & A

歡迎提問與交流